Detectarea optimismului si pesimismului

Rusti Emilia Noemi 341
Farcasi George Octavian 333
Diaconescu Alexandra 344

Introducere

Am analizat sentimentele exprimate in postari de tip tweet, pe care le-am clasificat in trei categorii: pozitiv, neutru si negativ, folosind 2 metode:

a. Algoritmul clasic: Naive Bayes
b. Novel approach: BERTweet

Setul de date

- Set-ul de date folosit este Sentiment Analysis Dataset (Shrivastava, 2021), preluat de pe Kaggle. Datele au fost colectate automat din tweet-uri publice si etichetate manual, pe baza sentimentului exprimat

- Pentru antrenare s-au folosit 26k date (train.csv), iar pentru test aproximativ 3500 (test.csv)

- O intrare contine:
    - text – tweet-ul propriu-zis, in format text
    - sentiment – eticheta : pozitiv/ negativ/ neutru

Preprocesare

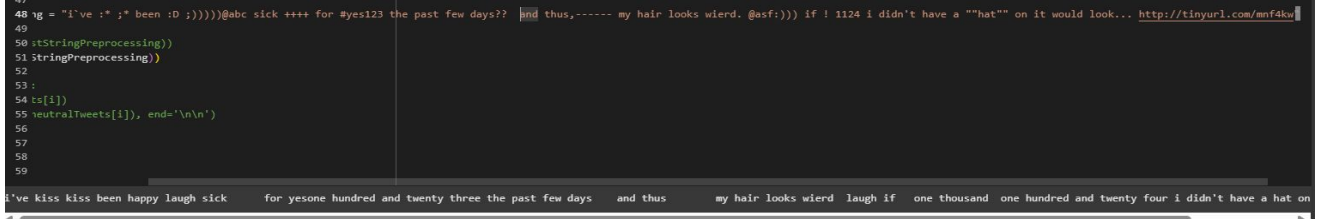

Pentru Naive Bayes:

- Eliminarea URL-urilor din tweet-uri.
- Eliminarea caracterelor repetitive si consecutive.
- Modificarea literelor mari în litere mici.
- Transformarea caracterelor speciale, cum ar fi semnele de punctuatie, într-un spatiu.
- Înlocuirea emoticoanelor si emoji-urilor cu descrierea lor textuala.
- Îndepartarea mentiunilor si a hashtag-urilor.
- Transformarea numerelor în cuvinte.
- Lematizarea cuvintelor pentru a le reduce la forma de baza.

Pentru BERTweet se adauga:

- Eliminarea duplicatelor
- Tokenizarea textelor, folosind vinai/bertweet-base
- Stratificare dupa etichetele de sentiment
- Construirea unui dataset compatibil cu PyTorch

Naive Bayes

- Pentru fiecare categorie de sentiment, se construieste un dictionar care retine frecventa fiecarui cuvant.

- Se calculeaza probabilitatile (si log-probabilitatile) fiecarui cuvant intr-o clasa, folosind smoothing Laplace pentru a evita probabilitatile zero pentru cuvintele nevazute.

- Pentru un tweet nou, se aduna log-probabilitatile tuturor cuvintelor apartinand fiecarei clase, iar tweetul este clasificat in functie de scorul maxim.

```
negativeTweetsWordsFrequency = getWordsFrequency(negativeTweets)
neutralTweetsWordsFrequency = getWordsFrequency(neutralTweets)
positiveTweetsWordsFrequency = getWordsFrequency(positiveTweets)

print("negative words freq:", len(negativeTweetsWordsFrequency))
print("neutral words freq:", len(neutralTweetsWordsFrequency))
print("positive words freq:", len(positiveTweetsWordsFrequency))
```

```
negative words freq: 10438
neutral words freq: 13505
positive words freq: 10806
```

```
def predictSentiments(tweet):
  tokens = preprocess(tweet)
  scores = {}
  for typeOfSentiment in ['negative', 'neutral', 'positive']:
    scores[typeOfSentiment] = sentimentPriorLog[typeOfSentiment]
    for token in tokens:
      scores[typeOfSentiment] += logLikelihoods[typeOfSentiment].get(token, 0)
  return max(scores, key=scores.get), scores
```

Acuratetea obtinuta este the 65%

BERTweet

- Am ales vinai/bertweet-base, bazat pe BERT, dar antrenat special pentru limbajul informal de pe Twitter.
- Folosește tokenul [CLS] din last_hidden_state care rezuma tweet-ul.
- Se aplica Dropout pentru regularizare si prevenirea overfitting-ului.
- Linear Layer produce scoruri (logits) pentru cele 3 clase: negativ, neutru, pozitiv.
- Se foloseste CrossEntropyLoss pentru antrenare, pe durata a 3 epoci.

```python
class TweetClassifier(nn.Module):
    def __init__(self, dropout_rate=0.3):
        super(TweetClassifier, self).__init__()
        self.backbone = AutoModel.from_pretrained("vinai/bertweet-base") # without c
        self.dropout = nn.Dropout(dropout_rate) # dropout layer to prevent overfitti
        self.classifier = nn.Linear(self.backbone.config.hidden_size, 3) #Linear lay
    def forward(self, input_ids, attention_mask):

        outputs = self.backbone(input_ids=input_ids, attention_mask=attention_mask)
        hidden_state = outputs.last_hidden_state
        pooled_output = hidden_state[:, 0]
        x = self.dropout(pooled_output)
        x = self.classifier(x)

        return x
```

Acuratetea obtinuta este the 80%

References

- Attention Is All You Need, Vaswani, Ashish and Shazeer, Noam and Parmar, Niki and Uszkoreit, Jakob and Jones, Llion and Gomez, Aidan N and Kaiser, Lukasz and Polosukhin, Illia, 2017
- BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding, Devlin, Jacob and Chang, Ming-Wei and Lee, Kenton and Toutanova, Kristina, 2019
- BERTweet: A pre-trained language model for English Tweets, Nguyen, Dat Quoc and Vu, Thanh and Nguyen, Anh Tuan, 2020
- XLM-T: A Multilingual Language Model for Twitter, Barbieri, Francesco and Espinosa-Anke, Luis and Camacho-Collados, Jose, 2021
- Sentiment Analysis Dataset, Abhinav Shrivastava, 2021

Multumim

Rusti Emilia Noemi 341
Farcasi George Octavian 333
Diaconescu Alexandra 344